




1. Quantidade de neurônios e camadas ocultas

Devido à maior complexidade na distribuição dos dados, não foi fácil encontrar configuração de rede que obtivesse ajuste satisfatório aos dados, de forma que uma rede capaz de resolver o problema só foi encontrada utilizando pelo menos três camadas ocultas.

Observando os contornos para cada neurônio em cada camada, percebe-se que os neurônios da primeira camada capturam características mais simples da distribuição, como distribuição das classes levando em consideração retas lineares. A segunda camada começa a apresentar características de curvas para a distribuição dos dados, e a terceira captura ainda mais características específicas dos dados, aglomerados as informações das curvas da segunda camada para gerar a classificação final. Observando esse comportamento dos neurônios dá indícios do motivo pelo qual redes com menos camadas ocultas não foram capazes de convergir bem durante o treinamento.

A variação de neurônios também mostrou que quanto mais neurônios utilizamos por camadas, mais características da distribuição conseguimos extrair. Alguns neurônios apresentaram as curvas de distribuição da classificação com formas semelhantes, o que pode indicar que resultados semelhantes poderiam ter sido obtidos com o uso de menos neurônios por camada.

2. Função de ativação

Para a resolução do exercício foram testados Tangente Hiperbólica, que foi capaz de atingir o test loss desejado, a função ReLu foi testada e também foi capaz de atingir bons resultados. O uso de Sigmóide como função de ativação também foi verificado, entretanto essa função de ativação não obteve bons resultados, muito provavelmente pelo fato de ser uma função que limita o valor da ativação entre 0 e 1. Diferente das funções tangente hiperbólica, -1 e 1, e Relu, 0 e infinito.

3. Regularização

Para a regularização foram testados três casos: L2, L1 e não utilizar regularização. Para os três casos foi possível obter um valor de perda de teste capaz de satisfazer a condição pedida, e não foram observados casos onde o treinamento levasse a um overfitting aos dados de treinamento caso não utilizássemos regularização.

4. Learning rate

Foram testados diferentes valores de learning rate para a rede, valores abaixo de 0,01 não foram capazes de convergir em tempo razoável, valores acima de 0,1 também não foram capazes de convergir.